Teoria da Informação

Trabalho Prático nº 1

Entropia, Redundância e Informação Mútua

Introdução

Período de execução: 3 aulas práticas laboratoriais

Ritmo de execução esperado para avaliação:

- Semana 1: 1 a 5
- Semana 2: 6 (determinação da informação mútua)
- Semana 3: 6 (finalização)

Formato de Entrega:

Entrega final (código completo + relatório): Submissão na InfoEstudante

Prazo de Entrega:

19 de Outubro, sexta-feira, 23h59

Esforço extra aulas previsto: 15h/aluno

Objectivo: Pretende-se que o aluno adquira sensibilidade para as questões

fundamentais de teoria de informação, em particular informação,

redundância, entropia e informação mútua.

Trabalho Prático

1. Escreva uma rotina em Matlab que dada uma fonte de informação P com um alfabeto $A=\{a_1,...,a_n\}$ determine e visualize o **histograma de ocorrência dos seus símbolos**.

2. Escreva o código que dada uma fonte de informação P com um alfabeto $A=\{a_1,...,a_n\}$ determine o **limite mínimo teórico para o número médio de bits por símbolo**.

3. Usando as rotinas desenvolvidas nas alíneas 1) e 2) determine a distribuição estatística e o número médio de bits por símbolo para as seguintes fontes:

- kid.bmp
- homer.bmp
- homerBin.bmp
- guitarSolo.wav
 - Nota: alfabeto de som no intervalo [-1, 1[(limite superior aberto);
 se o intervalo entre amostras sucessivas for 'd', o alfabeto será {-1, -

1+d, -1+2d, ..., 1-d}. 'd' depende da dimensão do alfabeto (256 se 8 bits de quantização, 65536 se 16 bits, ...)

• english.txt (nesta fonte considere somente os símbolos regulares do alfabeto, ignorando acentos e símbolos de pontuação)

Nota: a chamada das rotinas indicadas neste ponto e nos seguintes deve ser feita num script, por exemplo, main.m

- Apresente os resultados.
- Analise e comente os resultados.

Será possível comprimir cada uma das fontes de forma não destrutiva? Se Sim, qual a compressão máxima que se consegue alcançar? Justifique.

Notas:

- A leitura de ficheiros de texto deverá ser efectuada com recurso às funções fopen e fscanf (sintaxe idêntica à da linguagem C – consultar a ajuda do Matlab em caso de dúvida)
 - Poderá também utlizar as funções double e num2str (conversão de string para número e vice-versa)
- As rotinas **imRead** e **wavRead** permitem, respectivamente, efectuar a leitura de ficheiros de imagem (bmp, gif, jpeg, etc.) e wav.
- A função **imfinfo** dá informação sobre uma dada imagem (e.g., dimensão, número de bits por pixel, etc.)
- As suas sintaxes são as que seguidamente se apresentam:
- $Y = imread(filename, format) \circ \cup Y = imread(filename)$

filename – string com o nome do ficheiro que contém a imagem a ler
 format – string com a identificação do formato do ficheiro (não especificado → inferido pela análise do ficheiro)

Y - matriz de pixels (bidimensional para uma imagem de níveis de cinzento ou indexada e tridimensional para uma imagem RGB)

Exemplo: A = imread('imagem.bmp')

Para visualizar uma imagem aberta poderá usar a função 'imshow(x)'

Exemplo: imshow(A)

info = imfinfo(filename)

filename – string com o nome do ficheiro que contém a imagem cuja informação se pretende obter

info – estrutura de dados com informação sobre a imagem

Exemplo:

info = imfinfo('imagem.bmp');
disp(info.Width)

• [Y, fs, nbits] = wavread(filename) ou Y = wavread(filename)

filename – string com o nome do ficheiro que contém o clip de áudio a ler

 Y - Amostras (amplitude) do áudio; caso o áudio seja estéreo, Y conterá dois vectores de valores (amostras)

fs - Frequência de amostragem **nbits -** Número de bits por amostra

Exemplo: [Y, fs, nbits] = wavread('audio.wav')

Para reproduzir um som em matlab poderá usar a função 'wavplay(y, fs)'

Exemplo: wavplay(Y, fs)

4. Usando as rotinas de codificação de Huffman que são fornecidas, determine o número médio de bits por símbolo para cada uma das fontes de informação usando este código.

Analise e comente os resultados.

🔈 Analise e comente a variância dos comprimentos dos códigos resultantes.

Será possível reduzir-se a variância? Se sim, como pode ser feito em que circunstância será útil?

Nota:

A rotina hufflen determina o número de bits do código Huffman necessários à codificação de um conjunto de símbolos com uma dada frequência de ocorrência. A sua sintaxe é a seguinte:

HLen= hufflen(freqOcurr)

freqOcurr = [f(1),f(2),...,f(n)] – vector com a frequência de ocorrência dos n símbolos em que f(i) corresponde à frequência de ocorrência do símbolo número i do alfabeto.

HLen = [len(1),len(2),...,len(n)] – vector com o número de bits em que len(i) representa o número de bits necessários à codificação do símbolo número i.

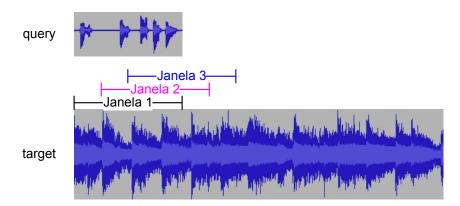
Exemplo:

hufflen([1,0,4,2,0,1]) => ans = [3,0,1,2,0,3]

5. Repita a alínea 3) aplicando agrupamentos de símbolos, isto é, admitindo que cada símbolo é na verdade uma sequência de dois símbolos contíguos.

Analise e comente os resultados.

Em muitas situações reais, é necessário procurar-se uma onda sonora conhecida, num sinal genérico. Nomeadamente, num contexto de comunicação em ambiente ruidoso é necessário detectar o sinal original transmitido no sinal recebido no destino, corrompido com ruído. Noutras aplicações, por exemplo em sistemas de identificação musical como o Shazam¹, é necessário procurar-se um trecho de uma música numa base de dados. Em qualquer dos casos, é possível aplicar um conjunto vasto de técnicas. Neste ponto, será calculada a **informação mútua** entre o sinal a pesquisar (query) e o sinal onde pesquisar (target), utilizando uma **janela deslizante**, de acordo com a ilustração seguinte:



Deste modo, a query será comparada com secções diferentes do target (correspondentes às janelas ilustradas). Por outras palavras, a query "deslizará" sobre o target, sendo calculada a informação mútua em cada uma das janelas. O intervalo entre janelas consecutivas é desginado por **passo**.

a) Escreva uma rotina em Matlab que, dada a query, o target, um alfabeto $A=\{a_1,...,a_n\}$ e o passo, devolva o vector de valores de informação mútua em cada janela.

Simulação:

Dados:

¹ http://www.shazam.com; nestes sistemas, o utilizador marca o número do fornecedor de serviço no seu telemóvel, direcciona o microfone para a origem do som durante alguns segundos (de 3 a 20, dependendo do fornecedor) e aguarda uma mensagem escrita contento a identificação da música (artista, título, etc.).

```
query = [26410595808]; (vector 1x10)
target = [68972499491480122632074954852780748574
322735274996]; (vector 1x50)
alfabeto = 0:10;
step = 1
```

Resultados a obter:

- b) Usando o ficheiro "guitarSolo.wav" como query, determine a variação da informação mútua entre este e os ficheiros "target01 repeat.wav" e "target02 repeatNoise.wav". Defina um passo com valor de ¼ do comprimento do vector da query (valor arredondado).
- > Visualize graficamente a evolução da informação mútua ao longo do tempo para cada caso.
- > Analise e comente os resultados.

Nota: Utilize apenas o primeiro canal de cada ficheiro (primeira coluna)

- c) Pretende-se agora simular um pequeno simulador de identificação de música. Usando o ficheiro "guitarSolo.wav" como query e os ficheiros Song*.wav como target:
 - determine a evolução da informação mútua para cada um dos ficheiros
 - calcule a informação mútua máxima em cada um deles
 - e, finalmente, apresente os resultados da pesquisa, seriados por ordem decrescente de informação mútua. Defina um passo com valor de ¼ da duração da query.
- Apresente os resultados (informação mútua em cada caso).
- Analise e comente os resultados.